

# Controle ótimo

Antonio M. N. Lima

DEE/CEEI/UFCG


# Introdução

- ☞ 1696 pode ser considerado o marco zero da teoria de controle ótimo. Neste ano J. Bernoulli publicou *A new problem that mathematicians are invited to solve* no *Acta Eruditorum*, e desafiou os matemáticos com o problema da braquistócrona.
- ☞ *Given two points A and B in a vertical plane, what is the curve traced out by a particle acted on only by gravity, which starts at A and reaches B in the shortest time.*
- ☞ Braquistócrona é de origem grega: brachistos (βραχιστος) é “o mais curto”, e chronos (χρονος) é “tempo”.

Figure 1: Problema da braquistócrona.

- O problema da braquistócrona pode ser considerado o primeiro problema de cálculo variacional.
- Newton foi desafiado a resolvê-lo num dia 1696, e o resolveu no dia seguinte. A prova de que a curva solução é um segmento de uma cicloide, também foi encontrada por Leibniz, L'Hôpital, e pelos irmãos Bernoulli (Johann e Jakob).
- Johann resolveu o problema usando uma analogia baseada no caminho da luz refratada por camadas transparentes de índices de refração variáveis. De fato, Johann encontrou inicialmente uma prova incorreta e desafiou seu irmão Jakob a encontrar a prova correta. Jakob encontrou a prova correta, e Johann tentou usá-lo com se fosse de sua autoria.

# Solução-distância



**Figure 2:**  $x(\theta) = r(\theta - \sin(\theta))$ ,  $y(\theta) = -r(1 - \cos(\theta))$ ,  $0 \leq \theta \leq \theta_B$ ,  
 $x(\theta_B) = x_B$  e  $y(\theta_B) = y_B$ .

$$T = \int_A^B (\nu)^{-1} ds, \frac{1}{2} m \nu^2 = mgy, \nu = (2gy)^{1/2} \quad (1)$$

$$ds = (dx^2 + dy^2)^{1/2} = (1 + y'^2)^{1/2} dx, y' \triangleq \frac{dy}{dx} \quad (2)$$

$$T = \int_A^B (1 + y'^2)^{1/2} (2gy)^{-1/2} dx \quad (3)$$

$$f = (1 + y'^2)^{1/2} (2gy)^{-1/2} \quad (4)$$

$$f^* = \arg \min_{f \in \mathcal{F}} T \quad (5)$$

Equação de Euler-Lagrange

$$\frac{\partial f}{\partial y} - \frac{d}{dx} \left( \frac{\partial f}{\partial y'} \right) = 0 \quad (6)$$

# Problema de Bolza - Oskar Bolza, 1913

Se não há restrições para  $\mathbf{x}(t)$  ou  $\mathbf{u}(t)$ , e se  $t_i$  e  $t_f$  são fixos, o problema de controle ótimo de tempo contínuo pode ser definido como: qual a trajetória do vetor  $\mathbf{u} : [t_i, t_f] \subset \mathbb{R} \rightarrow \mathbb{R}^{n_u}$  que minimiza o índice de desempenho  $J(\mathbf{u})$

$$J(\mathbf{u}) = \varphi(\mathbf{x}(t_f)) + \int_{t_i}^{t_f} L(\mathbf{x}(t), \mathbf{u}(t), t) dt, \quad (7)$$

sujeito a

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), t), \mathbf{x}(t_i) = \mathbf{x}_i, \quad (8)$$

where

- $[t_i, t_f]$  é o intervalo de tempo de interesse,
- $\mathbf{x} : [t_i, t_f] \rightarrow \mathbb{R}^{n_x}$  é o vetor de estados,
- $\varphi : \mathbb{R}^{n_x} \times \mathbb{R} \rightarrow \mathbb{R}$  é a uma função de custo terminal,
- $L : \mathbb{R}^{n_x} \times \mathbb{R}^{n_u} \times \mathbb{R} \rightarrow \mathbb{R}$  é a uma função de custo intermediária,
- $\mathbf{f} : \mathbb{R}^{n_x} \times \mathbb{R}^{n_u} \times \mathbb{R} \rightarrow \mathbb{R}^{n_x}$  é um campo vetorial.

Restrições podem ser incluídas no índice de desempenho usando uma função vetorial de multiplicadores de Lagrange variantes no tempo  $\lambda : [t_i, t_f] \mapsto \mathbb{R}^{n_\lambda}$ , para definir um índice de desempenho aumentado  $\bar{J}$  :

$$\bar{J}(\mathbf{u}) = \varphi(\mathbf{x}(t_f)) + \int_{t_i}^{t_f} \left\{ L(\mathbf{x}, \mathbf{u}, t) + \lambda^T(t) [\mathbf{f}(\mathbf{x}, \mathbf{u}, t) - \dot{\mathbf{x}}] \right\} dt \quad (9)$$

Definindo uma função hamiltoniana  $\mathcal{H}$

$$\mathcal{H}(\mathbf{x}(t), \mathbf{u}(t), \lambda(t), t) = L(\mathbf{x}(t), \mathbf{u}(t), t) + \lambda(t)^T \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), t),$$

o índice de desempenho aumentado por ser re-escrito como

$$\bar{J}(\mathbf{u}) = \varphi(\mathbf{x}(t_f)) + \int_{t_o}^{t_f} \left\{ \mathcal{H}(\mathbf{x}(t), \mathbf{u}(t), \lambda(t), t) - \lambda^T(t) \dot{\mathbf{x}} \right\} dt. \quad (10)$$

# Condições de primeira ordem

Se  $t_i$  e  $t_f$  são constants, uma variação infinitesimal  $\delta \mathbf{u}$  resultará em variações infinitesimais de  $\delta \mathbf{x}$  e  $\delta \bar{J}$ , i.e.,

$$\begin{aligned} \delta \bar{J} = & \left[ \left( \frac{\partial \varphi}{\partial \mathbf{x}} - \lambda^T \right) \delta \mathbf{x} \right]_{t=t_f} + \left[ \lambda^T \delta \mathbf{x} \right]_{t=t_i} \dots \\ & + \int_{t_i}^{t_f} \left\{ \left( \frac{\partial \mathcal{H}}{\partial \mathbf{x}} + \dot{\lambda}^T \right) \delta \mathbf{x} + \left( \frac{\partial \mathcal{H}}{\partial \mathbf{u}} \right) \delta \mathbf{u} \right\} dt \end{aligned} \quad (11)$$

Considerando que os multiplicadores de Lagrange são arbitrários, podemos escolhe-los para que os termos associados a  $\delta \mathbf{x}(t)$  e  $\delta \mathbf{x}(t_f)$  sejam iguais a zero, i.e.,

$$\dot{\lambda}(t)^T = -\frac{\partial H}{\partial \mathbf{x}}, \quad (12)$$

$$\lambda(t_f)^T = \frac{\partial \varphi}{\partial \mathbf{x}} \Big|_{t=t_f}. \quad (13)$$



## Condições de primeira ordem+

A escolha feita para  $\lambda(t)$  resulta que

$$\delta \bar{J} = \int_{t_i}^{t_f} \left\{ \left( \frac{\partial H}{\partial \mathbf{u}} \right) \delta \mathbf{u} \right\} dt. \quad (14)$$

Considerando que o estado inicial é constante  $\delta \mathbf{x}(t_i) = 0$ , o mínimo valor  $\bar{J}$  é obtido quando  $\delta \bar{J} = 0$ . Isto resulta na condição de estacionariedade dada por

$$\frac{\partial H^T}{\partial \mathbf{u}} = \mathbf{0}. \quad (15)$$

- As equações (8), (12), (13), e (15) são denominadas de condições de primeira ordem que são necessárias para obter o mínimo de  $J$ .
- A equação (12) é denominada de co-estado (ou estado adjunto).
- A equação (13) e  $\mathbf{x}(t_i) = \mathbf{x}_i$  são condições de contorno (ou de transversalidade).

# Existência da lei de controle ótimo

- Essa teoria não trata da existência da lei de controle ótimo que minimize o índice de desempenho  $J$ .
- As condições necessárias de otimalidade, definem duas condições de contorno e são úteis para:
  - encontrar soluções analíticas para problemas específicos;
  - definir algoritmos numéricos para buscar soluções de problemas genéricos;
  - verificar se uma solução extrema que satisfaz as condições necessárias de otimalidade realmente produz um mínimo, e determinar qual o tipo de mínimo que é alcançado.
- Condições suficientes para problemas não lineares genéricos e distinções entre condições suficientes para mínimos locais fracos/fortes e globais fortes.
- Vale destacar que um dos pontos chave da teoria é a existência do multiplicador de Lagrange,  $\lambda(t)$ .

# Restrição terminal - Formulação variacional

Considerando o problema de determinar a trajetória de  $\mathbf{u}$  que minimiza o índice de desempenho  $J(\mathbf{u})$  sujeito a um conjunto de restrições terminais do tipo

$$\psi(\mathbf{x}(t_f), t_f) = \mathbf{0}.$$

sen  $\psi : \mathbb{R}^{n_x} \times \mathbb{R} \mapsto \mathbb{R}^{n_\psi}$  uma função vetorial. Para esse problema, a formulação variacional, além das condições (8), (12), (13), e (15) exige que

$$\left( \frac{\partial \varphi}{\partial \mathbf{x}}^T + \frac{\partial \psi}{\partial \mathbf{x}}^T \nu - \lambda \right)^T \bigg|_{t_f} \delta \mathbf{x}(t_f) + \left( \frac{\partial \varphi}{\partial t} + \frac{\partial \psi}{\partial t}^T \nu + H \right) \bigg|_{t_f} \delta t_f = \mathbf{0},$$

sendo  $\nu \in \mathbb{R}^{n_\psi}$  um multiplicador de Lagrange associado à restrição terminal,  $\delta t_f$  é a variação do tempo final, e  $\delta \mathbf{x}(t_f)$  é a variação do estado final; se o tempo final e o estado final são fixados, então  $\delta t_f = 0$  e o segundo da expressão se anula. Se na restrição terminal  $\mathbf{x}_j(t_f)$  é fixado, então  $\delta \mathbf{x}_j(t_f)$  também é nulo.

- É uma forma de resolver problemas de controle ótimo (política ótima) sem recorrer a métodos variacionais.
- Foi proposta por Bellman na década de 1950, e é uma extensão da teoria de Hamilton-Jacobi.
- Princípio de otimalidade de Bellman
  - "An optimal policy has the property that regardless of what the previous decisions have been, the remaining decisions must be optimal with regard to the state resulting from those previous decisions".
  - O uso desse princípio permite limitar o número de leis de controle ótimas candidatas que devem ser investigadas.
  - O uso desse princípio permite explicita que a lei ótima ótima deve ser determinada do tempo final para o tempo inicial.

Considerando o problema de determinar a trajetória de  $\mathbf{u}$  que minimiza o índice de desempenho  $J(\mathbf{u})$ ,

$$J(\mathbf{u}) = \varphi(\mathbf{x}(t_f)) + \int_{t_i}^{t_f} L(\mathbf{x}(t), \mathbf{u}(t), t) dt, \quad (16)$$

sujeito a

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), t), \mathbf{x}(t_i) = \mathbf{x}_i, \varphi(\mathbf{x}(t_f), t_f) = \mathbf{0}. \quad (17)$$

Para esse problema, usando o princípio de otimalidade de Bellman, obtém-se

$$-\frac{\partial J^*}{\partial t} = \min_{\mathbf{u}} \left( L + \frac{\partial J^*}{\partial \mathbf{x}} \mathbf{f} \right),$$

a qual é denominada de Equação de Hamilton-Jacobi-Bellman.

# Controle ótimo de tempo discreto

A programação dinâmica também aplica-se a sistemas de tempo discreto

$$\mathbf{x}(k+1) = \mathbf{f}(\mathbf{x}(k), \mathbf{u}(k), k), \mathbf{x}(N_0) = \mathbf{x}_0,$$

$k \in \mathbb{R}_{\geq 0}$ ,  $\mathbf{x}(k) \in \mathbb{R}^{n_x}$ ,  $\mathbf{f} : \mathbb{R}^{n_x} \times \mathbb{R}^{n_u} \times \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}^{n_x}$ . O objetivo é determinar a sequência de ações de controle  $\{\mathbf{u}(k)\}$ ,  $k = N_0, \dots, N_f - 1$ , que minimiza

$$J(\mathbf{u}) = \varphi(\mathbf{x}(N_f)) + \sum_{k=N_0}^{N_f-1} L(\mathbf{x}(k), \mathbf{u}(k), k).$$

A programação dinâmica também é aplicada aos sistemas combinatórios, que são sistemas discretos com estados e ações de controles quantizados. A programação dinâmica discreta, entretanto, sofre com a "maldição da dimensionalidade", que faz com que os cálculos e requisitos de memória cresçam dramaticamente com o tamanho do problema.

## Restrição do estado terminal: integrador duplo

$$J(u) = \int_{t_i}^{t_f} u(t)^2 dt, \quad t_i = 0, \quad t_f = 1,$$

$$\dot{x}_1(t) = x_2(t), \quad \dot{x}_2(t) = u(t),$$

$$x_1(0) = 1, \quad x_2(0) = 1, \quad x_1(1) = 0, \quad x_2(1) = 0.$$

$$\boxed{\mathcal{H}(\mathbf{x}(t), \mathbf{u}(t), \lambda(t), t)} \Rightarrow \mathcal{H} = \frac{1}{2}u^2 + \lambda_1 x_2 + \lambda_2 u,$$

$$\boxed{\frac{\partial H^T}{\partial \mathbf{u}} = \mathbf{0}} \Rightarrow u + \lambda_2 = 0 \implies u = -\lambda_2,$$

$$\boxed{\dot{\lambda}(t)^T = -\frac{\partial H}{\partial \mathbf{x}}} \Rightarrow \dot{\lambda}_1 = 0, \quad \dot{\lambda}_2 = -\lambda_1.$$

Desse modo

$$\lambda_1(t) = c_1, \quad \lambda_2(t) = -c_1 t + c_2,$$

sendo  $c_1$  e  $c_2$  constantes a serem determinadas e

$$u(t) = c_1 t - c_2.$$

## Restrição terminal: integrador duplo+

A restrição terminal é

$$\psi(\mathbf{x}(t_f)) = [x_1(1), x_2(1)]^T = [0, 0]^T,$$

de modo que  $\mathbf{x}(t_f) = \mathbf{0}$  e  $\delta\mathbf{x}(t_f) = 0$ . Semelhantemente  $\delta t_f = 0$ , já que  $t_f = 1$ ; todas as condições de (11) são satisfeitas. Para determinar  $a$  e  $b$ , substitui-se  $u(t) = c_1 t - c_2$  na equação de estado

$$\dot{x}_1(t) = x_2(t), \quad \dot{x}_2(t) = c_1 t - c_2,$$

e avalia-se a solução

$$x_2(t) = \frac{1}{2}c_1 t^2 - c_2 t + c_3, \quad x_1(t) = \frac{1}{6}c_1 t^3 - \frac{1}{2}c_2 t^2 + c_3 t + c_4,$$

em  $t = t_i = 0$

$$1 = c_4, \quad 1 = c_3,$$

e em  $t = t_f = 1$

$$0 = \frac{1}{6}c_1 - \frac{1}{2}c_2 + c_3 + c_4, \quad 0 = \frac{1}{2}c_1 - c_2 + c_3 \Rightarrow c_1 = 18, c_2 = 10, \quad \boxed{u = 18t - 10}.$$



# Regulador linear quadrático

Quando o índice de desempenho é

$$J = \frac{1}{2} \mathbf{x}(t_f)^T \mathbf{S}_f \mathbf{x}(t_f) + \frac{1}{2} \int_{t_i}^{t_f} (\mathbf{x}(t)^T \mathbf{Q} \mathbf{x}(t) + \mathbf{u}(t)^T \mathbf{R} \mathbf{u}(t)) dt, \quad (18)$$

com  $\mathbf{S}_f$  e  $\mathbf{Q}$  sendo matrizes semi-definidas positivas,  $\mathbf{R}$  uma matriz positiva definida, e

$$\dot{\mathbf{x}}(t) = \mathbf{A} \mathbf{x}(t) + \mathbf{B} \mathbf{u}(t), \quad \mathbf{x}(t_i) = \mathbf{x}_i, \quad (19)$$

configura-se o problema do regulador linear quadrático. Neste caso, usando as condições de otimalidade, determina-se que o vetor de controle é

$$\mathbf{u}(t) = -\mathbf{K}(t) \mathbf{x}(t), \quad (20)$$

sendo o vetor de ganhos

$$\mathbf{K}(t) = \mathbf{R}^{-1} \mathbf{B}^T \mathbf{S}(t), \quad (21)$$

na qual  $\mathbf{S}(t)$  é a solução de

$$-\dot{\mathbf{S}} = \mathbf{A}^T \mathbf{S} + \mathbf{S} \mathbf{A} - \mathbf{S} \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^T \mathbf{S} + \mathbf{Q}, \quad \mathbf{S}(t_f) = \mathbf{S}_f. \quad (22)$$

Quando  $t_f \rightarrow \infty$  e  $(\mathbf{A}, \mathbf{B})$  é estabilizável (os modos estáveis são controláveis e os modos não controláveis são estáveis), a equação diferencial de Ricatti converge para  $\mathbf{S}_\infty$ . Deste modo, o vetor de controle é

$$\mathbf{K} = \mathbf{R}^{-1} \mathbf{B}^T \mathbf{S}_\infty \quad (23)$$

sendo  $\mathbf{S}_\infty$  uma matrix positiva definida que é solução de

$$\mathbf{A}^T \mathbf{S}_\infty + \mathbf{S}_\infty \mathbf{A} - \mathbf{S}_\infty \mathbf{B} \mathbf{R}^{-1} \mathbf{B}^T \mathbf{S}_\infty + \mathbf{Q} = \mathbf{0} \quad (24)$$

Além disto, se  $(\mathbf{A}, \mathbf{C})$  é observável,  $\mathbf{C}^T \mathbf{C} = \mathbf{Q}$ , então o sistema

$$\dot{\mathbf{x}} = (\mathbf{A} - \mathbf{B} \mathbf{K}) \mathbf{x} \quad (25)$$

é assintoticamente estável. O regulador linear quadrático proporciona uma forma de estabilizar qualquer sistema linear que seja estabilizável.

# Problema linear-quadrático

Seja

$$\dot{\mathbf{x}} = A\mathbf{x} + B\mathbf{u},$$

a lei de realimentação

$$\mathbf{u}(t) = -K\mathbf{x}(t),$$

e a função de custo

$$V = \int_t^T [\mathbf{x}^T(\tau)Q\mathbf{x}(\tau) + \mathbf{u}^T(\tau)R\mathbf{u}(\tau)]d\tau$$

com  $Q$  e  $R$  sendo matrizes simétricas, isto é  $Q = Q^T$  e  $R = R^T$ . A lei de realimentação modifica a equação dinâmica do sistema para

$$\dot{\mathbf{x}} = A\mathbf{x} + B(-K\mathbf{x}) = (A - BK)\mathbf{x} = A_c(t)\mathbf{x}.$$

# Resolução do problema

Com o horizonte finito,  $[t, T]$ ,  $K$  é variante no tempo e deste modo,  $A_c$  é variante no tempo e

$$\mathbf{x}(\tau) = \Phi_c(\tau, t)\mathbf{x}(t)$$

A função de custo pode ser re-escrita como

$$V = \int_t^T \left[ \underbrace{\mathbf{x}^T(\tau)}_{(\Phi_c(\tau, t)\mathbf{x}(t))^T} Q \underbrace{\mathbf{x}(\tau)}_{\Phi_c(\tau, t)\mathbf{x}(t)} + \underbrace{\mathbf{u}^T(\tau)}_{(-K\mathbf{x}(\tau))^T} R \underbrace{\mathbf{u}(\tau)}_{-K\mathbf{x}(\tau)} \right] d\tau$$

$$V = \mathbf{x}^T(t) \left\{ \int_t^T \Phi_c^T(\tau, t) [Q + K^T R K] \Phi_c(\tau, t) d\tau \right\} \mathbf{x}(t)$$

$$V = \mathbf{x}^T(t) M(t, T) \mathbf{x}(t)$$

$$M(t, T) = \int_t^T \Phi_c^T(\tau, t) [Q + K^T R K] \Phi_c(\tau, t) d\tau$$

# Resolução do problema+

A função de custo  $V$  depende do tempo e  $L$  não é necessariamente constante

$$V(t) = \int_t^T \mathbf{x}^T(\tau)[Q + K^T R K] \mathbf{x}(\tau) d\tau = \int_t^T \mathbf{x}^T(\tau) L(\tau) \mathbf{x}(\tau) d\tau$$

sendo  $L = Q + K^T R K$ . Desta equação acima pode-se escrever que

$$\frac{dV(t)}{dt} = -\mathbf{x}^T(\tau) L(\tau) \mathbf{x}(\tau) \Big|_{\tau=t} = -\mathbf{x}^T(t) L(t) \mathbf{x}(t)$$

Entretanto

$$\frac{dV(t)}{dt} = \dot{\mathbf{x}}^T(t) M(t, T) \mathbf{x}(t) + \dot{\mathbf{x}}^T(t) \dot{M}(t, T) \mathbf{x}(t) + \mathbf{x}^T(t) M(t, T) \dot{\mathbf{x}}(t)$$

com

$$\dot{M}(t, T) = \frac{\partial M(t, T)}{\partial t}$$

# Resolução do problema+

Utilizando a equação do sistema realimentado obtemos

$$\frac{dV(t)}{dt} = \mathbf{x}^T(t) \left[ A_c^T(t) M(t, T) + \dot{M}(t, T) + M(t, T) A_c(t) \right] \mathbf{x}(t)$$

obtém-se uma segunda expressão para  $\frac{dV(t)}{dt}$ . Essas duas expressões (21) e (22) são formas quadráticas que dependem do estado inicial que é arbitrário. Desse modo

$$-L(t) = A_c^T(t) M(t, T) + \dot{M}(t, T) + M(t, T) A_c(t)$$

ou

$$-\dot{M}(t, T) = M(t, T) A_c(t) + A_c^T(t) M(t, T) + L(t).$$

A condição inicial necessária para a solução dessa equação é  $M(T, T) = 0$ , obtida de

$$M(t, T) = \int_t^T \Phi_c^T(\tau, t) [Q + K^T R K] \Phi_c(\tau, t) d\tau.$$

# Resolução do problema+

A função de custo é

$$V(t) = \mathbf{x}^T(t)M(t, T)\mathbf{x}(t)$$

com  $M(t, T)$  obtido pela solução de (22) que pode ser re-escrita em termos de  $A$ ,  $B$ ,  $K$ ,  $Q$  e  $R$  como

$$-\dot{M} = M[A - BK] + [A - BK]^T M + Q + K^T R K.$$

O problema é determinar  $K$  que minimize essa função de custo, isto é, encontrar  $\hat{M}$  tal que

$$\hat{V} = \mathbf{x}^T \hat{M} \mathbf{x} < \mathbf{x}^T M \mathbf{x}, \forall \hat{M} \neq M.$$

Para determinar matriz de ganhos considera-se que  $\exists \hat{K}$  que resulta um valor ótimo, isto é, um valor mínimo da função de custo  $\hat{M}$  que também satisfaz a

$$-\dot{\hat{M}} = \hat{M} [A - B\hat{K}] + [A - B\hat{K}]^T \hat{M} + Q + \hat{K}^T R \hat{K}.$$

## Resolução do problema+

Deste modo, se  $K = \hat{K} + k \Rightarrow M = \hat{M} + m$  então

$$- \left( \dot{\hat{M}} + \dot{m} \right) - \left( -\dot{\hat{M}} \right) = -\dot{m},$$

$$-\dot{m} = mA_c + A_c^T m + \hat{L},$$

$$A_c = A - B \left( \hat{K} + k \right),$$

e

$$\hat{L} = \left( \hat{K}^T R - \hat{M} B \right) k + k^T \left( R \hat{K} - B^T \hat{M} \right) + k^T R k.$$

Consequentemente

$$m(t, T) = \int_t^T \Phi_c^T(\tau, t) \hat{L} \Phi_c(\tau, t) d\tau.$$

Se  $\hat{V}$  é mínimo  $\mathbf{x}^T \hat{M} \mathbf{x} \leq \mathbf{x}^T M \mathbf{x}$ , então

$$\mathbf{x}^T \hat{M} \mathbf{x} = \mathbf{x}^T (M - m) \mathbf{x} = \mathbf{x}^T M \mathbf{x} - \mathbf{x}^T m \mathbf{x} \leq \mathbf{x}^T M \mathbf{x}.$$



## Resolução do problema+

Dado que  $\mathbf{x}^T \mathbf{m} \mathbf{x} \geq 0$  é necessário assegurar que  $\mathbf{x}^T \hat{\mathbf{L}} \mathbf{x} > 0, \forall \mathbf{x}$ . Isto é garantido se

$$R\hat{K} - B^T \hat{M} = \hat{K}^T R - \hat{M}B = 0$$

ou

$$\hat{K} = R^{-1} B^T \hat{M} \Rightarrow \hat{L} = k^T R k.$$

Nessas condições

$$-\dot{\hat{M}} = \hat{M}A + A^T \hat{M} + \hat{M}B R^{-1} B^T \hat{M} + Q$$

que é denominada de equação de Riccati. Um método usado na resolução dessa equação é a integração numérica e, como  $\hat{M}$  é simétrica, existem  $n(n+1)/2$  equações escalares acopladas. Essas equações são resolvidas na ordem de tempo inversa já que a condição inicial conhecida é  $M(T, T) = 0$ , ou seja, a integração numérica fornece

$$M(t, T), t < T$$